

Pandas to biblioteka w Pythonie, która służy do analizy i manipulacji danymi. Jest szczególnie użyteczna w obszarze analizy danych, eksploracyjnej analizy danych (EDA) i przetwarzania danych. Pandas oferuje potężne narzędzia do pracy z danymi tabelarycznymi (podobnymi do arkuszy kalkulacyjnych), danymi czasowymi i innymi typami struktur danych.

Instalacja w PyCharm:

File > Settings > Project {nazwa projektu} > Python Interpreter

LUB w CMD

C:\Users\Your Name>pip install pandas

```
import pandas as pd
```

Pandas dostarcza dwóch nowych struktur danych:

Series: Jednowymiarowa struktura danych (podobna do listy lub kolumny w tabeli) zawierająca dane oraz etykiety indeksu. Indeksy w Pandas Series mogą być dowolnymi wartościami (np. liczby, napisy), a nie tylko liczbami jak w listach. Indeks może być domyślnie generowany lub dostarczony przez użytkownika.

```
import pandas as pd
```

```
#Utworzony jest obiekt Pandas Series, który jest jednowymiarową strukturą  
danych. Dane to lista [10, 20, 30, 40], Indeksy to ['a', 'b', 'c', 'd'].  
Indeks jest jak etykieta przypisana do każdej wartości.
```

```
data = pd.Series([10, 20, 30, 40], index=['a', 'b', 'c', 'd'])
```

```
print(data)
```

```
# Pobranie wartości z serii dla indeksu 'c'
```

```
print(data['c'])
```

DataFrame: Dwuwymiarowa tabela z wierszami i kolumnami (podobna do tabeli w bazie danych lub arkusza kalkulacyjnego), gdzie każda kolumna może zawierać różne typy danych

```
import pandas as pd
```

```
# Tworzenie słownika data, klucze ('Imię', 'Wiek', 'Ocena') reprezentują  
kolumny a wartości to listy zawierające dane, które trafiają do tych kolumn.
```

```
data = {  
    'Imię': ['Anna', 'Jan', 'Katarzyna', 'Tomasz'],  
    'Wiek': [22, 21, 24, 23],  
    'Ocena': [4.5, 5.0, 3.5, 4.0]  
}
```

```
# Funkcja pd.DataFrame(data) zamienia słownik na obiekt DataFrame.
```

```
df = pd.DataFrame(data)
print(df)
```

Rezultat końcowy działania kodu:

	Imię	Wiek	Ocena
0	Anna	22	4.5
1	Jan	21	5.0
2	Katarzyna	24	3.5
3	Tomasz	23	4.0

DataFrame może zostać również stworzone z listy słowników lub list:

```
import pandas
ListaSloownikow = [
    {'Imię': 'Anna', 'Wiek': 22, 'Ocena': 4.5},
    {'Imię': 'Jan', 'Wiek': 21, 'Ocena': 5.0}
]

ListaList = [
    ['Anna', 22, 4.5],
    ['Jan', 21, 5.0]
]
for osoba in ListaSloownikow: print(f"{osoba['Imię']} ma {osoba['Wiek']} lat
i ocenę {osoba['Ocena']}")
for osoba in ListaList: print(f"{osoba[0]} ma {osoba[1]} lat i ocenę
{osoba[2]}")
df1 = pandas.DataFrame(ListaSloownikow)
df2 = pandas.DataFrame(ListaList)
print(df1)
print(df2)
df3 = pandas.DataFrame(ListaList, columns=['Imię', 'Wiek', 'Ocena'])
print(df3)
```

Wczytywanie danych

CSV

`pd.read_csv()`, to funkcja Pandas używana do wczytywania pliku CSV. Argument 'nazwa_pliku.csv' to nazwa pliku, który chce się załadować (może to być ścieżka do pliku). Domyślnie przyjmuje, że wartości w pliku są oddzielone przecinkami (`sep=','`).

```
df = pd.read_csv('nazwa_pliku.csv')
# Wczytywanie z określonym separatorem (np. średnik)
df = pd.read_csv('nazwa_pliku.csv', sep=';')
```

XLSX

Openpyxl to domyślny silnik Pandas do obsługi plików Excel w formacie .xlsx. Jeśli brakuje biblioteki openpyxl należy ją dodać.

```
df = pd.read_excel('nazwa_pliku.xlsx', sheet_name='nazwa_arkusza')
```

Internet

```
url = 'https://www.example.com/dane.csv'  
df = pd.read_csv(url)
```

Dodatkowe materiały:

Film: <https://www.youtube.com/watch?v=Mc0CUFjEhGU>

Więcej informacji:

<https://www.w3schools.com/python/pandas/default.asp>

<https://analitik.edu.pl/python-pandas-mega-tutorial/>

Zad 1. Wczytaj plik demografia.csv, a następnie go wyświetl.

Dodaj do funkcji read_csv() decimal oraz na_values

Podpowiedź: **na_values=['NA', 'n/a', 'NaN']**: Definiuje listę wartości, które powinny być traktowane jako brakujące (NA). Można dostosować listę zgodnie z plikiem.

Zad 2.

Znajdź kraj, w którym odnotowano największy przyrost ludności w roku 2022.

Użyj metody idxmax(), która zwraca indeks pierwszego wystąpienia maksymalnej wartości w serii lub ramce danych.

Podpowiedź: **skipna**: domyślnie ustawiony na True, co oznacza, że wartości NaN są pomijane podczas obliczeń. Jeśli ustawisz go na False, uwzględn również wartości NaN.

Zad 3.

Znajdź największy przyrost ludności we wszystkich latach. Wyświetl nazwę kraju, którego dotyczy ten przyrost.

Użyj metody max() do całej DataFrame, z wyłączeniem kolumny „KRAJ”.

Użyj metody idxmax() aby określić, w którym roku był największy przyrost.

Ponownie skorzystaj z metody idxmax() w celu znalezienia „indeksu wiersza” w ramach tej kolumny, w którym wystąpił największy przyrost.

Zad 4.

Stwórz DataFrame zawierający dane o pracownikach firmy.

Dane:

1. Numer identyfikacyjny pracownika: 1, 2, 3, 4, 5
2. Imię: Anna, Jan, Katarzyna, Tomasz, Michał
3. Nazwisko: Kowalska, Nowak, Wiśniewska, Kaczmarek, Zieliński
4. Stanowisko: Manager, Programista', Konsultant, Programista, Manager
5. Wiek: 35, 28, 40, 30, 45
6. Pensja (w PLN): 8000, 4500, 6000, 5500, 7000

Wykonaj poniższe operacje na tych danych:

- a) Wybierz pracowników, którzy mają pensję większą niż 5000 PLN.
- b) Posortuj pracowników według wieku (od najmłodszych do najstarszych).
- c) Zgrupuj pracowników według stanowiska i oblicz średnią pensję w każdej grupie.
- d) Utwórz ramkę danych zawierającą informacje o pracownikach, którzy zmienili stanowisko (np. po awansie) i połącz ją z ramką pierwszego terminu na podstawie wspólnego klucza (np. numer identyfikacyjny).
- e) Zapisz przygotowany DataFrame do pliku CSV.
- f) Wczytaj dane z pliku CSV i sprawdź, czy wczytanie przebiegło poprawnie.

Zad 5.

Stwórz DataFrame z danymi studentów (nr_albumu, imię, nazwisko, oceny z kolokwium), Następnie:

- a. Wybierz studentów, którzy mają ocenę większą niż 4.
- b. Posortuj studentów według wieku.
- c. Zgrupuj studentów według ocen i oblicz średnią wieku w każdej grupie.
- d. Utwórz ramkę danych protokołu ocen z poprawy a następnie połącz ją z ramką pierwszego terminu na podstawie wspólnego klucza (jakiego?).
- e. Zapisz przygotowany DataFrame do pliku CSV.
- f. Wczytaj dane z pliku CSV i sprawdź poprawność wczytania.
- g. Dodaj nowego studenta do istniejącego DataFrame.
- h. Znajdź unikalne wartości w kolumnie z ocenami.
- i. Sprawdź, ile studentów ma ocenę równą 5

Dane:

- 1. *Nr_albumu*: 1, 2, 3, 4, 5
- 2. *Imię*: Anna, Jan, Katarzyna, Tomasz, Michał
- 3. *Nazwisko*: Kowalska, Nowak, Wiśniewska, Kaczmarek, Zieliński
- 4. *Ocena*: 4.5, 3.0, 5.0, 4.0, 2.5,
- 5. *Wiek*: [22, 21, 24, 23, 25]